PUCPR

PONTIFÍCIA UNIVERSIDADE CATÓLICA DO PARANÁ

DATA ANALYTICS / PROJETO BASEADO EM PROBLEMAS

RA1

Ingestão e preparação dos dados

Adoção de gatos no Austin Animal Center

Projeto Adoção de gatos no Austin Animal Center: características associadas à adoção

Curso e turma Bacharelado em Sistemas de Informação • 6º período, turma U (noite) • 2026/2

Professor ou professora Profa. Marina de Lara

Equipe Ayla Micheluzzi e Gabriel Baczinski

Repositório https://github.com/aylamich/MiauData (pasta `adocao-gatinhos/`)

Entrega Curitiba • 21/10/2026

RA1 / 01

Problema e perguntas analíticas

Contexto do projeto, problema investigado e perguntas que orientaram a seleção e a preparação dos dados.

Contexto e problema

Abrigos de animais recebem milhares de gatos por ano: alguns são adotados em poucos dias, outros esperam meses. Cada dia a mais no abrigo ocupa uma vaga que outro animal precisaria, aumenta o custo e o risco de o gato adoecer. Existe a crença de que gatos pretos, adultos ou idosos e sem nome são adotados mais devagar. Se for verdade, os dados embasam campanhas de conscientização contra o preconceito na adoção e ajudam o abrigo a dar mais visibilidade a esses gatos; se não for, a crença não deveria orientar as decisões do abrigo. São afetados os gatos, o abrigo e quem procura um animal para adotar.

Problema: quais características de um gato, na chegada ao abrigo (idade, cor, sexo, castração, ter nome, condição e tipo de entrada e mês de entrada), estão associadas à chance de ele ser adotado e ao tempo que ele espera até a adoção?

A raça não foi incluída: 95% das passagens são de gatos sem raça definida, registrados como `Domestic Shorthair` (83,5%), `Domestic Medium Hair` (7,9%) ou `Domestic Longhair` (3,6%), o que deixa pouca variação para comparar. O atributo `raca` permanece no conjunto de dados apenas como descrição.

Objetivo e recorte

Objetivo do RA1: obter, avaliar e preparar os dados do abrigo para que as perguntas possam ser respondidas nos próximos RAs. As perguntas não são respondidas aqui.

- **Período:** entradas de 01/10/2013 a 05/05/2025 (as bases estão congeladas desde então).
- **População:** gatos (`Animal Type = Cat`) do Austin Animal Center, abrigo municipal de Austin (Texas, EUA).
- **Unidade de análise:** a passagem de um gato pelo abrigo, isto é, uma entrada e a saída correspondente. O mesmo gato pode ter várias passagens.
- **Limites:** os dados são de um único abrigo, de política no-kill (quase não sacrifica animais), então os resultados valem para esse abrigo e não podem ser generalizados. Os dados mostram associação, não causa: se gatos pretos esperarem mais, isso não prova que esperam por serem pretos.

Perguntas analíticas

As regras abaixo valem para todas as perguntas:

- **Tempo até a adoção:** `dias_no_abrigo` das passagens com `desfecho = adocao`, separando as adoções com subtipo `Foster` (cerca de 30%), cujo tempo pode incluir dias em lar temporário.
- **Chance de adoção:** percentual das passagens com saída que terminam em `adocao`. `rto-adopt` não conta como adoção (ver Q9).
- **Tempo e chance juntos:** o tempo só considera os gatos adotados. Se um grupo é mais transferido, os que demorariam saem da conta e o grupo parece adotado mais rápido; por isso cada comparação de tempo é acompanhada da chance de adoção do mesmo grupo.
- **Comparação dentro da faixa etária** (P1 e P3 a P7): filhotes são adotados mais rápido e também chegam mais sem nome, sem castração e na primavera e no verão. Sem separar por idade, a diferença observada pode ser apenas efeito da idade.

- **Medida de comparação:** a mediana, porque o tempo no abrigo é muito assimétrico (mediana de 7 dias, máximo de 1.745).

ID	Pergunta a investigar	Dados necessários
P1	Gatos pretos esperam mais e são adotados menos do que gatos de outras cores?	Chance e tempo com `is_black` verdadeiro × falso (frajolas pela `cor_principal`)
P2	Quanto mais velho o gato chega, mais ele espera?	Chance e tempo por `faixa_etaria`; `idade_entrada_meses`
P3	Gatos que chegam sem nome esperam mais?	Chance e tempo com e sem nome: `tem_nome`, `nome_com_asterisco`
P4	Chegar castrado aumenta a chance de adoção ou encurta a espera? Isso muda entre machos e fêmeas?	Chance e tempo, `castrado` × não castrado, separando por `sexo` (só sexo conhecido)
P5	Gatos feridos ou doentes são adotados menos ou esperam mais?	Chance e tempo por `condicao_entrada`
P6	Gatos perdidos e entregues pelo dono têm destinos diferentes?	Distribuição de `desfecho` por `tipo_entrada`
P7	O mês de entrada altera o tempo até a adoção ("temporada de filhotes")?	Tempo até a adoção pelo mês de `data_entrada`

Todas as perguntas usam também `dias_no_abrigo`, `desfecho` e `faixa_etaria`, no período inteiro (2013 a 2025).

Viabilidade inicial

Unindo a entrada e a saída de cada passagem, obtém-se quanto tempo o gato ficou no abrigo e qual foi o desfecho; as demais colunas são as características investigadas. Todas as colunas das perguntas existem no conjunto preparado, e os grupos são grandes: o menor grupo relevante, gatos idosos adotados, tem 542 passagens.

Lacunas: as passagens sem saída (dados censurados) e o tempo das adoções `Foster`, detalhadas em Limitações e pendências (Seção 05). Também não há dados sobre fatores como foto ou divulgação de cada gato.

RA1 / 02

Fontes de dados e ingestão

Origem dos dados e como eles são carregados no ambiente do projeto. São duas tabelas do mesmo abrigo, ligadas pelo `Animal ID`.

Ficha da fonte F1

Identificação F1 • Austin Animal Center Intakes (10/01/2013 to 05/05/2025) • ID `wter-evkm`

Origem e acesso Prefeitura de Austin (City of Austin Open Data Portal, plataforma Socrata) • https://data.austintexas.gov/d/wter-evkm • acesso em 06/10/2026

Formato e volume CSV (dados) e JSON pela API (metadados) • 173.812 registros, 69.324 de gatos • 12 atributos

Cobertura 01/10/2013 a 05/05/2025 • cada entrada de animal no abrigo de Austin (Texas, EUA)

Condições de uso Domínio público (licença informada nos metadados: Public Domain); sem necessidade de cadastro

Ficha da fonte F2

Identificação F2 • Austin Animal Center Outcomes (10/01/2013 to 05/05/2025) • ID `9t4d-g238`

Origem e acesso Prefeitura de Austin (City of Austin Open Data Portal, plataforma Socrata) • https://data.austintexas.gov/d/9t4d-g238 • acesso em 06/10/2026

Formato e volume CSV (dados) e JSON pela API (metadados) • 173.775 registros, 69.399 de gatos • 12 atributos

Cobertura 01/10/2013 a 05/05/2025 • cada saída de animal do abrigo (adoção, transferência, devolução etc.)

Condições de uso Domínio público (licença informada nos metadados: Public Domain); sem necessidade de cadastro

Relação com o problema

F1 traz as características do gato na chegada (nome, idade, sexo e castração, cor, tipo e condição de entrada) e a data de entrada; F2 traz a data de saída e o desfecho. Juntas, permitem calcular o tempo de cada passagem e o seu destino, o que apoia todas as perguntas (P1 a P7).

Os metadados obtidos pela API mostram que as bases estão congeladas: a última atualização foi em 19/05/2025, quando o abrigo trocou de sistema. Mostram também que o portal não tem dicionário de dados (nenhuma das 12 colunas tem descrição); o significado de cada coluna foi deduzido dos nomes e conferido nos valores (Seção 03).

Procedimento de ingestão

Etapa	Procedimento ou parâmetro	Evidência no repositório
1	Download do export CSV de cada base (`/api/views/{id}/rows.csv?accessType=DOWNLOAD`), em blocos de 1 MB, gravado sem alterações; download dos metadados em JSON (`/api/views/{id}.json`)	`src/ingestao.py` (`baixar_csv`, `baixar_metadados`)
2	Leitura com todas as colunas como texto, para que toda conversão de tipo seja explícita: `pd.read_csv(..., dtype=str)` na seção 2 do notebook e `spark.read.csv(..., header=True)` na seção 4.1. Separador vírgula, codificação UTF-8, cabeçalho na 1ª linha	Notebook, seções 2 e 4.1
3	Contagem das linhas baixadas comparada com a contagem oficial da API (`$select=count(*)`); resultado gravado em arquivo	`src/ingestao.py` (`linhas_no_portal`); `data/raw/info_download.txt`

Escolhas. A ingestão é em lote (carga única), e não em streaming, porque as bases não recebem dados novos. Os dados vêm do CSV, que mantém os formatos originais; na API, as datas já vêm convertidas e os campos vazios são omitidos. Como o RA1 avalia a qualidade do dado tal como é publicado, a API foi usada só para metadados e conferência. O portal é público e não usa senha nem token.

Resultado da ingestão

No download de 06/10/2026, as quantidades coincidiram com o portal: 173.812 linhas em `data/raw/intakes.csv` e 173.775 em `data/raw/outcomes.csv`. Os metadados ficam em `data/raw/metadados_intakes.json` e `metadados_outcomes.json`. Não há etapa manual: um único comando (`python src/ingestao.py`) refaz tudo.

RA1 / 03

Compreensão e qualidade

O que cada registro representa e as verificações de qualidade, todas na seção 3 do notebook `projeto_adocao_gatinhos.ipynb` (pandas). Cada problema foi medido nos dados; os que eram esperados e não apareceram também foram registrados.

Unidade de observação Em F1, uma linha representa uma entrada de um animal no abrigo; em F2, uma saída. No conjunto preparado, uma linha é uma passagem de um gato (entrada + saída).

Identificação dos registros Nas bases brutas não há chave única: o `Animal ID` se repete quando o animal volta ao abrigo (2.785 gatos com mais de uma entrada, até 7). No conjunto final, a chave é `animal_id` + `passagem`.

Dicionário inicial dos dados

Atributo	Significado	Tipo e formato	Unidade ou domínio
Animal ID	Identificador do animal; liga F1 e F2	Texto	"A" + 6 dígitos (ex.: A774102)
Name	Nome do animal	Texto livre	Vazio em 39% das entradas de gatos; às vezes peso, ID ou número
DateTime (F1)	Data e hora da entrada	Texto `MM/DD/YYYY hh:mm:ss AM`	01/10/2013 a 05/05/2025
DateTime (F2)	Data e hora da saída	Texto ISO `YYYY-MM-DDThh:mm:ss`, parte com fuso -05:00	Horário pouco confiável (Q5)
MonthYear	Mês e ano do evento	Texto	Repete DateTime (não usado)
Found Location (F1)	Endereço onde o animal foi encontrado	Texto	Não usado
Animal Type	Espécie	Texto categórico	Cat, Dog, Other, Bird, Livestock
Intake Type (F1)	Como o animal chegou	Texto categórico	Gatos: Stray, Owner Surrender, Public Assist, Abandoned, Euthanasia Request
Intake Condition (F1)	Condição na chegada	Texto categórico	18 valores (Normal, Injured, Sick, Nursing, Neonatal...)
Sex upon Intake / Outcome	Sexo e castração na mesma coluna	Texto categórico	Intact, Neutered ou Spayed + Male/Female; Unknown
Age upon Intake / Outcome	Idade no evento	Texto: número + unidade	Ex.: "2 years", "3 weeks"

Atributo	Significado	Tipo e formato	Unidade ou domínio
Breed	Raça	Texto categórico	111 valores; 95% "Domestic" (SRD)
Color	Cor da pelagem	Texto categórico	327 combinações (ex.: Black/White)
Date of Birth (F2)	Data de nascimento (estimada pelo abrigo)	Texto `YYYY-MM-DD`	Usada só para conferir a idade
Outcome Type (F2)	Desfecho da saída	Texto categórico	Adoption, Transfer, Return to Owner, Euthanasia, Died, Rto-Adopt, Disposal, Missing, Relocate
Outcome Subtype (F2)	Detalhe do desfecho	Texto categórico	Opcional (vazio em 41%); ex.: Foster, Partner

Diagnóstico de qualidade

ID	Verificação e regra	Resultado observado	Evidência
Q1	Ausentes • vazios por coluna	Nome vazio em 27.096 entradas (39%); desfecho vazio em 9 saídas; subtipo opcional	Notebook, seção 3.1
Q2	Duplicados • linhas idênticas; mesmo gato e mesmo minuto	23 linhas idênticas; 4 entradas registradas 2x (endereço diferente)	Notebook, seção 3.2
Q3	Unicidade • `Animal ID` com mais de uma entrada	2.785 gatos com várias passagens (69.324 entradas para 66.239 gatos); não dá para unir as bases só pelo ID	Notebook, seção 3.3
Q4	Tipos e formatos • datas e idade	Tudo chega como texto; datas em formatos diferentes em cada base; 1.671 saídas com fuso, todas à meia-noite	Notebook, seção 3.4
Q5	Valor impossível • saída antes da entrada (63.047 gatos com 1 entrada e 1 saída)	327 casos, todos no mesmo dia; horários repetidos (09:00 = 2.116, 00:00 = 1.791): o erro é o horário, não a data	Notebook, seção 3.5
Q6	Idade • conversão do texto e conferência com Date of Birth	1 idade negativa ("-4 years"); 662 "0 years", dos quais 516 tinham 0 dias de vida na entrada (recém-nascidos, não erro)	Notebook, seção 3.6
Q7	Nomes • padrões de peso, ID ou número	2.895 nomes inválidos (ex.: "103 Grams", "A840400", "#2")	Notebook, seção 3.7
Q8	Sexo e castração • valores da coluna	5 valores que juntam as duas informações; 5.031 Unknown	Notebook, seção 3.8
Q9	Categorias de entrada e desfecho • frequência e definição	18 condições, várias raras; Nursing com 177 gatos de 1 ano ou mais; Rto-Adopt (249) e Disposal (164) sem definição no portal	Notebook, seção 3.9

ID	Verificação e regra	Resultado observado	Evidência
Q10	Cores e raças • número de categorias e maiúsculas/minúsculas	327 cores e 111 raças, a maioria com poucos gatos; diferença de maiúsculas: 0 (não existe)	Notebook, seção 3.10
Q11	Consistência entre F1 e F2 • raça, cor e sexo do mesmo gato	0 conflitos (não existe)	Notebook, seção 3.11
Q12	Outliers • IQR do tempo no abrigo	6,9% acima do limite de 74 dias; máximo de 1.745 dias; 123 passagens acima de 1 ano	Notebook, seção 3.12
Q13	Adoções Foster • tempo por subtipo	Cerca de 30% das adoções; mediana de 55 dias, contra 14 nas demais	Notebook, seção 3.13
Q14	Data de nascimento depois da saída	12 casos	Notebook, seção 3.14

A seção 3 do notebook termina numa tabela-resumo com os 24 problemas, a relevância de cada um e o que fazer com ele.

Impacto dos problemas identificados

Prioridade alta, porque impedem calcular o tempo no abrigo: Q3 (sem tratar, um gato com 3 entradas e 3 saídas viraria 9 linhas na junção) e Q5 (tempos negativos). Também é prioritário o que distorce as perguntas: Q13 aumenta o tempo das adoções Foster, Q6 afeta a P2 e Q7 afeta a P3.

Prioridade média: Q1, Q2, Q4, Q8, Q9 e Q10, resolvidos com conversão, padronização ou agrupamento. **Não comprometem:** Q12 (estadias longas são plausíveis em abrigo e são justamente o foco das perguntas), Q14 (a data de nascimento não entra no conjunto final) e Q11, que não existe.

RA1 / 04

Limpeza e preparação

Os tratamentos estão nas seções 4 (limpeza), 5 (transformação) e 6 (conjunto final) do mesmo notebook, em PySpark e Spark SQL, com a justificativa de cada decisão logo acima do código. A regra geral foi tratar só os problemas encontrados na Seção 03 e, quando não era possível provar que um registro estava errado, manter e sinalizar em vez de apagar.

Registro das decisões

Decisão e diagnóstico D5 • pareamento de entradas e saídas • relacionado a Q3 e Q5

Problema e abrangência
Atinge todas as 69.324 entradas e 69.399 saídas de gatos. Como o `Animal ID` se repete, a junção comum pelo ID gera combinações sem sentido (o gato A774102, com 7 entradas e 7 saídas, viraria 49 linhas).

Tratamento e justificativa
Cada entrada foi ligada à primeira saída do mesmo gato depois dela e antes da próxima entrada dele (Spark SQL, com `ROW_NUMBER` e `LEAD`). Numa segunda rodada, as entradas sem par aceitaram uma saída livre do mesmo dia, porque o horário das saídas não é confiável (Q5). Assim cada passagem tem no máximo uma saída, sem inventar pares.

Implementação Notebook, seção 5.1

Validação após o tratamento
68.566 pares na 1ª rodada e 333 na 2ª; nenhuma saída usada duas vezes; 410 passagens sem saída, tratadas em D6.

Decisão e diagnóstico D6 • passagens sem saída mantidas • dados censurados

Problema e abrangência
410 passagens ficaram sem saída; 372 delas são de 2025 (22% das entradas daquele ano): gatos que ainda estavam no abrigo quando a base parou.

Tratamento e justificativa
Mantidas com `desfecho = sem_saida` e `dias_no_abrigo` vazio. Removê-las faria os anos recentes parecerem ter estadias mais curtas, porque são justamente os gatos que estavam demorando (censura à direita). A decisão sobre como analisá-las fica para a etapa de análise.

Implementação Notebook, seções 5.1 e 5.4

Validação após o tratamento
As 410 passagens aparecem com `sem_saida` e são os únicos vazios de `data_saida` e `dias_no_abrigo` no conjunto final.

Decisão e diagnóstico D8 • estadias longas mantidas • relacionado a Q12

Problema e abrangência
Pelo IQR, 6,9% das estadias (acima de 74 dias) seriam outliers; 123 passagens passam de 1 ano, até 1.745 dias.

Tratamento e justificativa
Mantidas, com a flag `estadia_acima_1_ano`. Estadias de alguns meses são comuns em abrigo, os gatos que demoram são o foco das perguntas e não há como provar que são erro. Com a flag, a análise pode ser feita com e sem esses casos; a comparação pela mediana já reduz o efeito deles.

Implementação Notebook, seção 5.3

Validação após o tratamento
123 passagens marcadas (0,18%); nenhuma linha removida.

Decisão e diagnóstico D9 • nomes inválidos • relacionado a Q1 e Q7

Problema e abrangência
Coluna Name: 27.096 entradas sem nome e 2.895 com peso, ID ou número no lugar do nome.

Tratamento e justificativa
Criadas `tem_nome` (verdadeiro só para nome válido) e `nome_com_asterisco` (nome iniciado por *, de significado não documentado, guardado à parte para não assumir nada). Um "nome" como "103 Grams" não é um nome, e contá-lo distorceria a P3.

Implementação Notebook, seção 4.5

Validação após o tratamento
Os padrões de peso, ID e número não aparecem como nome válido.

Resumo das intervenções

Decisão	Ação executada	Impacto nos dados	Evidência
D1	Filtro `Animal Type = Cat`	F1: 173.812 → 69.324; F2: 173.775 → 69.399 registros	Notebook, seção 4.1
D2 (Q2)	Remoção de duplicados; na mesma entrada registrada 2x, fica a primeira	23 linhas idênticas e 4 entradas repetidas removidas	Notebook, seção 4.2
D3 (Q4)	Conversão das datas com o formato de cada base	2 colunas de data deixam de ser texto	Notebook, seção 4.3
D4 (Q6, Q14)	Idade em meses (semana = 7, mês = 30,44, ano = 365,25 dias); idade negativa vira vazio; "0 years" mantido como recém-nascido	`idade_entrada_meses`; 1 vazio. Date of Birth não entra no resultado	Notebook, seção 4.4
D5 (Q3, Q5)	Pareamento em duas rodadas (Spark SQL)	68.899 passagens com saída	Notebook, seção 5.1
D6	Passagens sem saída mantidas como `sem_saida`	410 passagens	Notebook, seções 5.1 e 5.4
D7 (Q5)	`dias_no_abrigo` = data de saída − data de entrada, sem a hora	327 tempos negativos → 0	Notebook, seção 5.2
D8 (Q12)	Estadias longas mantidas, com `estadia_acima_1_ano`	123 passagens marcadas	Notebook, seção 5.3

Decisão	Ação executada	Impacto nos dados	Evidência
D9 (Q1, Q7)	`tem_nome` e `nome_com_asterisco`	2 colunas booleanas	Notebook, seção 4.5
D10 (Q8)	Separação em `sexo` e `castrado`, pela entrada (a castração na saída seria efeito do abrigo)	`sexo` com 3 valores; `castrado` vazio em 5.031	Notebook, seção 4.6
D11	Faixa etária: filhote (< 1 ano), adulto, idoso (≥ 10 anos), conforme Quimby et al. (2021)	45.783 / 21.521 / 2.004 passagens	Notebook, seção 5.5
D12 (Q10)	Primeira raça e primeira cor; menos de 100 passagens → "Outra" (corte testado contra 20, 50, 200 e 500); `is_black` só para o gato todo preto	Raças 111 → 10; cores 327 → 26; menos de 1% em "Outra"	Notebook, seções 5.6 e 5.7
D13 (Q9)	Condições 18 → 7 (nursing sem tradução); tipos e desfechos traduzidos; rto-adopt e disposal com o nome original; desfecho ausente → desconhecido	`tipo_entrada`, `condicao_entrada`, `desfecho`	Notebook, seções 4.7 e 5.4
D14 (Q13)	Subtipo do desfecho mantido para separar as adoções Foster	`subtipo_desfecho`	Notebook, seção 5.4

RA1 / 05

Conjunto de dados resultante

A saída do RA1 e as verificações que mostram que ela está pronta para as próximas etapas.

Arquivo ou conjunto final `gatos_ra1.csv` • `data/processed/` • CSV com cabeçalho, separador vírgula, UTF-8

Unidade de observação final Uma linha representa uma passagem de um gato pelo abrigo: 69.309 passagens de 66.239 gatos, de 01/10/2013 a 05/05/2025, com chave `animal_id` + `passagem`

Dicionário atualizado Tabela abaixo; também no `README.md` do repositório

Atributo	Tipo	Descrição
`animal_id` / `passagem`	texto / inteiro	Gato e número da passagem (1ª, 2ª...)
`data_entrada` / `data_saida`	data	Datas da passagem (saída vazia quando sem saída)
`dias_no_abrigo`	inteiro	Dias entre a entrada e a saída
`estadia_acima_1_ano`	booleano	Estadia superior a 365 dias
`idade_entrada_meses` / `faixa_etaria`	decimal / categoria	Idade na entrada; filhote, adulto ou idoso
`sexo` / `castrado`	categoria / booleano	macho, femea ou desconhecido; castrado na entrada
`raca` / `cor_principal`	categoria	Raça (10 categorias, só descritiva) e primeira cor (26)
`is_black`	booleano	Gato inteiramente preto
`tem_nome` / `nome_com_asterisco`	booleano	Chegou com nome válido; nome iniciado por *
`tipo_entrada` / `condicao_entrada`	categoria	Como chegou (5 tipos) e em que condição (7)
`desfecho` / `subtipo_desfecho`	categoria / texto	Destino (adocao, transferencia, devolvido_ao_dono, sem_saida...) e seu detalhe

Comparação antes e depois

Medida	Após ingestão	Após preparação	Explicação da diferença
Registros (gatos)	69.324 entradas e 69.399 saídas	69.309 passagens	Duplicados removidos (D2) e entradas pareadas com saídas (D5); passagens sem saída mantidas (D6)
Atributos	12 em cada base	19	Colunas derivadas (D3 a D14); MonthYear e Found Location não usados
Duplicados exatos	23	0	D2

Medida	Após ingestão	Após preparação	Explicação da diferença
Mesma entrada registrada 2x	4	0	D2
Saída antes da entrada	327	0	D7
Idade negativa	1	0 (vazio)	D4
Colunas de data como texto	2	0	D3
Categorias de condição / cor / raça	18 / 327 / 111	7 / 26 / 10	D12 e D13
Categorias de sexo (com castração)	5	3 (+ `castrado`)	D10

Verificações finais

- **Chave e duplicidade:** 69.309 linhas e 69.309 pares `animal_id` + `passagem` distintos, sem lacunas na numeração; nenhuma saída ligada a duas entradas.
- **Tipos:** relido pelo Spark com `inferSchema`, o arquivo devolve datas como data, dias como inteiro e flags como booleano.
- **Ausências:** os vazios restantes são esperados: 410 passagens sem saída, 1 idade negativa, 5.031 castrações de sexo desconhecido e o subtipo de desfecho, que é opcional.
- **Domínios:** `dias_no_abrigo` sem valores negativos; categorias dentro das listas da tabela acima.

Evidência: notebook, seções 6.2 (antes × depois, chave e vazios) e 6.3 (gravação e releitura com os tipos).

Limitações e pendências

- As passagens `sem_saida` são dados censurados: excluí-las ou tratá-las (por exemplo, com Kaplan-Meier) é decisão da etapa de análise.
- O tempo das adoções `Foster` pode incluir dias em lar temporário; elas devem ser analisadas à parte.
- Os significados de `Disposal` e do asterisco nos nomes não são documentados pelo portal.
- As comparações devem ser feitas dentro de cada faixa etária, porque a idade se relaciona com quase todas as outras características.
- Os resultados valerão para um único abrigo e mostrarão associação, não causa. Agregações, indicadores, visualizações e conclusões ficam para as próximas etapas.

RA1 / 06

Organização e reprodutibilidade

Como outra pessoa pode obter os dados e executar o fluxo completo do RA1.

Repositório e versão https://github.com/aylamich/MiauData • branch `main` • pasta `adocao-gatinhos/`

Ambiente Python 3.11+ (testado com 3.14) • Java 17+ para o Spark (testado com 23) • pandas 2.3.3, PySpark 4.2.0, pyarrow, requests, truststore, matplotlib, jupyter • `requirements.txt` com versões fixas • no Windows, o streaming do RA2 precisa do `winutils.exe` e do `hadoop.dll` (Hadoop 3.3.6) em `C:\hadoop\bin`

Localização dos artefatos

Artefato	Caminho ou forma de obtenção
Dados brutos	`data/raw/intakes.csv` e `outcomes.csv` (nunca editados), metadados em `data/raw/metadados_*.json` e registro do download em `data/raw/info_download.txt`; gerados por `src/ingestao.py`
Código de ingestão e preparação	`src/ingestao.py`; `notebooks/projeto_adocao_gatinhos.ipynb` (pandas na exploração; PySpark e Spark SQL na limpeza, na preparação e no streaming do RA2)
Dados preparados	`data/processed/gatos_ra1.csv`, gerado pelo notebook (seção 6.3)
Documentação e dependências	`README.md` • `docs/documentacao_ra1.docx` • `requirements.txt`

Passos para reprodução

Ordem	Instrução executável	Resultado esperado
1	Na pasta `adocao-gatinhos/`: `pip install -r requirements.txt` (e `java -version` para conferir o Java)	Bibliotecas instaladas sem erro; Java 17 ou mais novo
2	`python src/ingestao.py`	Mensagem "portal informa 173,812 linhas: ok" (e 173,775 para as saídas); `info_download.txt` atualizado
3	`jupyter nbconvert --to notebook --execute --inplace notebooks/projeto_adocao_gatinhos.ipynb`	O notebook executa sem erro (leva cerca de 5 minutos)
4	Abrir `data/processed/gatos_ra1.csv` ou as seções 6.2 e 6.3 do notebook	69.309 linhas e 19 colunas, chave única e tipos conferidos

Verificação da reprodução

O fluxo completo foi executado do zero por Ayla Micheluzzi em 02, 04 e 06/10/2026 (Windows 11, Python 3.14, Java 23), a partir das instruções acima. Nas três execuções, os CSVs brutos e o `gatos_ra1.csv` saíram idênticos (mesmo hash MD5). Em 17/10/2026, depois que os dois notebooks foram reunidos num só, o fluxo foi executado de novo e o `gatos_ra1.csv` manteve o mesmo hash. Os dados são públicos e não exigem credenciais.

RA1 / 07

Referências e anexos

Fontes utilizadas e materiais complementares que ajudam a verificar a entrega.

Referências

AUSTIN (Texas). Animal Services Office. **[Totais de entradas e saídas do Austin Animal Center: ano fiscal de 2024].** Austin: City of Austin, 2024. Disponível em: https://services.austintexas.gov/edims/document.cfm?id=430357. Acesso em: 6 out. 2026.

AUSTIN (Texas). **Austin Animal Center Intakes (10/01/2013 to 05/05/2025).** Austin: City of Austin Open Data Portal, 2025. Disponível em: https://data.austintexas.gov/Health-and-Community-Services/Austin-Animal-Center-Intakes/wter-evkm. Acesso em: 2 out. 2026.

AUSTIN (Texas). **Austin Animal Center Outcomes (10/01/2013 to 05/05/2025).** Austin: City of Austin Open Data Portal, 2025. Disponível em: https://data.austintexas.gov/Health-and-Community-Services/Austin-Animal-Center-Outcomes/9t4d-g238. Acesso em: 2 out. 2026.

QUIMBY, J. et al. 2021 AAHA/AAFP Feline Life Stage Guidelines. **Journal of Feline Medicine and Surgery**, v. 23, n. 3, p. 211-233, 2021. DOI: 10.1177/1098612X21993657.

Anexos

Identificação	Conteúdo	Localização
Anexo A	Tabela-resumo dos 24 problemas de qualidade e o que fazer com cada um	Notebook, fim da seção 3